

# 参数估计

参数(parameter)是刻画总体某方面概率特性的数量.

参数估计(parameter estimation): 对总体的分布形式已知, 但其中的某些参数未知, 从总体抽取样本, 用某种方法对这个参数进行估计. (机器学习中称为训练, training)

- 点估计——估计未知参数的值
- 区间估计——估计未知参数的取值范围, 并使此范围包含未知参数真值的概率为给定的值.

# 1 参数的点估计

- 矩估计
- 最大似然估计
- Bayes估计
- 点估计的评价标准

# 参数的点估计

根据样本构造一个统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ ,  
用它估计未知参数 $\theta$ , 称为点估计。

$\hat{\theta}(X_1, \dots, X_n)$ 称为 $\theta$  的估计量 (estimator)  
 $\hat{\theta}(x_1, \dots, x_n)$ 称为 $\theta$  的估计值 (estimate)

点估计的常用方法:

- 矩估计法
- 最大似然估计法
- 最大后验估计

# 矩估计

例  $X$ —某品牌手机的待机时间, 预估其 $\mu = E(X)$ , 抽取 $X_1, X_2, \dots, X_{100}$

$$\hat{\mu} = \frac{1}{100} \sum_{i=1}^{100} X_i = \bar{X}$$

用样本矩去估计相应的总体矩的估计方法称为矩估计法 (*method of moments*, MoM):

- ① 用样本  $k$  阶原点矩作为总体  $k$  阶原点矩的估计量, 建立含有待估参数的方程,
- ② 解出待估参数。

理论依据: 大数定律

设待估计的参数为 $\theta_1, \theta_2, \dots, \theta_m$

总体的  $k$  阶原点矩存在, 记为  $E(X^k) = \mu_k(\theta_1, \theta_2, \dots, \theta_m)$

样本 $X_1, X_2, \dots, X_n$ 的 $k$ 阶原点矩为 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

令  $\mu_k(\theta_1, \theta_2, \dots, \theta_m) = A_k, \quad k = 1, 2, \dots, m$

建立含未知参数  $\theta_1, \theta_2, \dots, \theta_m$  的方程组

解方程组, 得  $m$  个统计量:

$$\left. \begin{array}{l} \hat{\theta}_1(X_1, X_2, \dots, X_n) \\ \dots\dots\dots \\ \hat{\theta}_m(X_1, X_2, \dots, X_n) \end{array} \right\} \begin{array}{l} \text{未知参数} \\ \theta_1, \dots, \theta_m \\ \text{的矩估计量} \end{array}$$

代入一组样本值得未知参数  
 $\theta_1, \dots, \theta_m$  的矩估计值

$$\hat{\theta}_1 = \hat{\theta}_1(x_1, x_2, \dots, x_n)$$

$\dots\dots\dots$

$$\hat{\theta}_m = \hat{\theta}_m(x_1, x_2, \dots, x_n)$$

**例** 设总体 $X$ 有数学期望和方差:  $EX = \mu, DX = \sigma^2$   
 $X_1, \dots, X_n$ 是 $X$ 的一组样本,求  $\mu, \sigma^2$  的矩估计.

按矩估计法原理  $\begin{cases} \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \mu \\ A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 = E(X^2) = \sigma^2 + \mu^2 \end{cases}$

$\Rightarrow \begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = A_2 - \hat{\mu}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \\ = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2 = \frac{n-1}{n} S^2 \end{cases}$

不论总体服从什么分布, 如果总体期望  $\mu$  与方差  $\sigma^2$  存在, 则它们的矩估计量分别为  $\bar{X}$  和  $S_n^2$

例 设总体  $X$  的概率密度为

$$f(x) = \begin{cases} (\theta + 1)x^\theta, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$$

其中  $\theta > -1$  是未知参数.  $X_1, X_2, \dots, X_n$  是总体  $X$  的一个简单样本, 求  $\theta$  的矩估计.

解

$$E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^1 x(\theta + 1)x^\theta dx = \frac{\theta + 1}{\theta + 2},$$

令  $\frac{\theta + 1}{\theta + 2} = \bar{X}$

总体矩

样本矩

得  $\hat{\theta} = \frac{2\bar{X} - 1}{1 - \bar{X}}$

例 设总体  $X \sim U(\theta, \theta)$ ,  $\theta$  未知,  $X_1, \dots, X_n$  是  $X$  的样本, 试求  $\theta$  的矩估计量.

方法1 
$$\frac{1}{n} \sum_{i=1}^n X_i = \bar{X} = EX = \frac{\theta}{2}, \quad \hat{\theta} = 2\bar{X}$$

方法2 
$$\frac{1}{n} \sum_{i=1}^n X_i^2 = E(X^2) = \int_0^\theta \frac{1}{\theta} x^2 dx = \frac{\theta^2}{3}, \quad \hat{\theta} = \sqrt{\frac{3}{n} \sum_{i=1}^n X_i^2}$$

使用不同的矩, 可能得到不同的矩估计, 矩估计不唯一.  
一般使用低阶矩进行估计。



## 矩估计法的优点:

简单易行, 不需要知道总体是什么分布, 只需要知道总体  $k$  阶原点矩.

## 矩估计法的缺点:

- 当总体分布类型已知时, 没有充分利用分布提供的信息.
- 一般矩估计量不具有唯一性。
- 所需要的总体的某阶矩可能不存在。
- 求解方程组可能很困难。

# 最大似然估计

点估计的另外一种方法——最大似然估计法 (Maximum Likelihood Estimation, MLE)，是在**总体类型已知**条件下使用的一种参数估计方法。

首先由数学家Gauss在1821年提出，Fisher在1922年重新发现了这一方法，并研究了它的一些性质，得到广泛应用。

例：袋子中的黑球白球，不知哪种多？

每次取一个球，有放回取三次，结果第一次和第三次是白球，第二次是黑球。哪种球多？

白球多！

假设参数是未知的不变量，选择参数值使实验结果具有最大可能性，这就是最大似然法的基本思想。

设 $\theta$ 是盒中白球所占比例。

$$L(\theta) = P(X_1 = 1, X_2 = 0, X_3 = 1)$$

$$= P(X_1 = 1)P(X_2 = 0)P(X_3 = 1)$$

最大

$$= \theta (1 - \theta) \theta$$

# 求最大似然估计的一般步骤

## (1) 构造似然函数 $L(\theta)$

设 $X_1, \dots, X_n$ 是来自 $X$ 的样本,

$x_1, \dots, x_n$ 是 $X_1, \dots, X_n$ 的一个样本值;

若总体 $X$ 属离散型, 其分布律

$$P(X = x) = p(x; \theta), \quad \theta \in \Theta$$

似然函数

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

若总体 $X$ 属连续型, 其概率密度 $f(x; \theta), \theta \in \Theta$

似然函数

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

## (2) 求似然函数 $L(\theta)$ 的最大值点

选择使 $L(\theta)$ 达到最大的参数 $\hat{\theta}$ ，作为 $\theta$ 的估计，

$$L(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$$

$\hat{\theta}(x_1, \dots, x_n)$ 称为参数 $\theta$ 的最大似然估计值.

$\hat{\theta}(X_1, \dots, X_n)$ 称为参数 $\theta$ 的最大似然估计量.

$\theta$  可由下式求得：

$$\frac{dL(\theta)}{d\theta} = 0.$$

因 $L(\theta)$ 与 $\ln L(\theta)$ 在同一 $\theta$ 处取到极值，  
 $\theta$  的最大似然估计 $\hat{\theta}$  也可从下述方程解得：

$$\frac{d}{d\theta} \ln L(\theta) = 0.$$

**注1** 如果有多个未知参数, 如  $\theta_1, \dots, \theta_k$  时

设  $X$  的密度(或分布)为  $f(x; \theta_1, \dots, \theta_k)$

则似然函数为  $L(x_1, \dots, x_n; \theta_1, \dots, \theta_k)$

可令  $\frac{\partial L}{\partial \theta_i} = 0$  或  $\frac{\partial \ln L}{\partial \theta_i} = 0, i = 1, \dots, k.$  似然方程组

解方程组求得  $\theta_1, \dots, \theta_k$  的最大似然估计.

**注2** 用上述方法求参数的最大似然估计值有时行不通, 例如  $L(\theta)$  不是  $\theta$  的连续可导函数, 或参数空间是有界区域, 这时一般利用定义进行判断分析求解。

**注3** **最大似然估计不变性**

若  $\hat{\theta}$  是  $\theta$  的最大似然估计, 则  $g(\hat{\theta})$  是  $g(\theta)$  的最大似然估计.

**例** 考虑一系列独立的硬币投掷试验， $\theta$ 是每次正面向上的概率，固定 $n$ ， $k$ 是 $n$ 次投掷中正面向上的次数．试找出基于 $k$ 的 $\theta$ 的最大似然估计．

$$L(\theta) = C_n^k \theta^k (1-\theta)^{n-k}, \quad 0 \leq k \leq n.$$

$$\ln L(\theta) = \ln C_n^k + k \ln \theta + (n-k) \ln(1-\theta)$$

$$\hat{\theta}_{\text{ML}} = \frac{k}{n}$$

例 设总体  $X$  的概率密度为

$$f(x) = \begin{cases} (\theta + 1)x^\theta, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$$

其中  $\theta > -1$  是未知参数.  $X_1, X_2, \dots, X_n$  是总体  $X$  的一个简单样本, 求  $\theta$  的最大似然估计.

解: 似然函数为 
$$L(\theta) = \prod_{i=1}^n [(\theta + 1)x_i^\theta] = (\theta + 1)^n \left( \prod_{i=1}^n x_i \right)^\theta$$

对数似然函数为 
$$\ln L(\theta) = n \ln(\theta + 1) + \theta \sum_{i=1}^n \ln x_i$$

求导并令其为0 
$$(0 < x_i < 1)$$

$$\frac{d \ln L(\theta)}{d\theta} = \frac{n}{\theta + 1} + \sum_{i=1}^n \ln x_i = 0$$

解得 
$$\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln x_i} - 1$$

可以验证二阶导数 $<0$ ,  
所以是 $\theta$ 的最大似然估计



例 设总体  $X \sim N(\mu, \sigma^2)$ ,  $x_1, x_2, \dots, x_n$  是  $X$  的样本值, 求  $\mu, \sigma^2$  的最大似然估计.

解 
$$L(x_1, x_2, \dots, x_n; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \frac{1}{(2\pi)^{\frac{n}{2}} (\sigma^2)^{\frac{n}{2}}} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$\ln L = -\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} - \frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$$

似然方程组 
$$\begin{cases} \left( \frac{\partial}{\partial \mu} \ln L \right) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \left( \frac{\partial}{\partial (\sigma^2)} \ln L \right) = \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2(\sigma^2)} = 0 \end{cases}$$

$$\hat{\mu}_{mle} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad \hat{\sigma}_{mle}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

例 设 $X \sim G(p)$ ,  $x_1, \dots, x_n$ 是来自 $X$ 的一个样本值,  
试求参数 $p$ 与 $E(X)$ 的最大似然估计.

解:  $X$ 的分布律为: $P(X = k) = p(1-p)^{k-1}$ ,  $k = 1, 2, \dots$   
似然函数为

$$L(p) = \prod_{i=1}^n p(1-p)^{x_i-1} = p^n (1-p)^{\sum_{i=1}^n x_i - n},$$

$$\text{令 } \frac{d}{dp} \ln L(p) = \frac{n}{p} - \frac{\sum_{i=1}^n x_i - n}{1-p} = 0.$$

$$\text{解得 } p \text{ 的最大似然估计值 } \hat{p} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}$$

$$E(X) \text{ 的最大似然估计为 } \widehat{E(X)} = \frac{1}{\hat{p}} = \bar{x}$$

例 设某种元件使用寿命  $X$  的概率密度为

$$f(x) = \begin{cases} 2e^{-2(x-\theta)}, & x \geq \theta \\ 0, & \text{其他} \end{cases}$$

其中  $\theta > 0$  是未知参数. 设  $x_1, \dots, x_n$  是样本观测值, 求  $\theta$  的极大似然估计.

解: 当有一个  $x_i < \theta$ , 则  $L(\theta) = 0$

$$\text{当所有 } x_i \geq \theta \text{ 时} \quad L(\theta) = \prod_{i=1}^n [2e^{-2(x_i-\theta)}] = 2^n e^{-2\sum (x_i-\theta)}$$

$$\ln L(\theta) = n \ln 2 - 2 \sum_{i=1}^n (x_i - \theta)$$

$$\frac{d \ln L(\theta)}{d\theta} = 2n > 0 \quad L(\theta) \text{ 单调增加} \quad \text{且要满足 } \theta \leq x_i$$

$$\theta \text{ 的最大似然估计} \quad \hat{\theta} = \min\{x_1, x_2, \dots, x_n\}$$

例(2) 设 $X \sim U[a, b]$ ;  $a, b$ 未知,  $x_1, \dots, x_n$ 是一个样本值, 求 $a, b$ 的最大似然估计值。

解:  $X$ 的概率密度为
$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b; \\ 0 & , \text{其它} \end{cases}$$

$$\text{似然函数为 } L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_1, \dots, x_n \leq b; \\ 0 & , \text{其它} \end{cases}$$

似然函数只有当  $a \leq x_i \leq b, i = 1, 2, \dots, n$  时才能获得最大值, 且 $b - a$ 越小 (即 $a$  越大,  $b$  越小) ,  $L$  越大.

令  $x_{\min} = \min\{x_1, x_2, \dots, x_n\}, x_{\max} = \max\{x_1, x_2, \dots, x_n\}$

取  $\hat{a} = x_{\min}, \hat{b} = x_{\max}$  这就是  $a, b$  的最大似然估计值。

设某产品合格率 $p$ 可能的取值为 $0 < p < 1$ , 为估计 $p$ , 现从大批的该产品中随机抽查了10件, 发现恰有8件产品合格. 则该产品合格率 $p$ 的极大似然估计值为 [填空1]

# Bayes估计

- ① 把未知参数  $\theta$  看作随机变量，可用一个概率分布去描述，这个分布称为**先验分布**；
- ② 在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来，得到一个关于  $\theta$  的新分布，称为**后验分布**；
- ③ 基于  $\theta$  的后验分布进行估计。

$X = (x_1, x_2, \dots, x_n)$  是i.i.d.的一组抽样，

$$P(\theta | X) = \frac{P(X | \theta) \times P(\theta)}{P(X)}$$

由后验分布  $P(\theta | X)$  得到  $\theta$  的点估计有三种常用的方法:

- 使用后验分布的密度函数最大值点作为  $\theta$  的点估计的**最大后验估计(maximum a posteriori, MAP)**.

$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta|X).$$

- 使用后验分布的中位数作为  $\theta$  的点估计的**后验中位数估计**.

$$p(\theta \leq \hat{\theta}_{MED} | X) = 0.5.$$

- 使用后验分布的均值作为  $\theta$  的点估计的**后验期望估计**.

$$\hat{\theta}_B = \mathbb{E}[\theta|X] = \int \theta p(\theta|X) d\theta.$$

用得最多的是后验期望估计, 一般也称为**贝叶斯估计**.

## 最大后验估计(Maximum A Posteriori, MAP)

假设 $X = (x_1, x_2, \dots, x_n)$  是i.i.d.的一组抽样,

$$P(\theta | X) = \frac{P(X | \theta) \times P(\theta)}{P(X)}$$

$$\hat{\theta}_{MAP} = \operatorname{argmax} P(\theta | X)$$

$$= \operatorname{argmin} -\log P(\theta | X)$$

$$= \operatorname{argmin} -\log P(X | \theta) - \log P(\theta) + \log P(X) \quad (\text{贝叶斯定理})$$

$$= \operatorname{argmin} -\log P(X | \theta) - \log P(\theta) \quad (P(X) \text{ 因为与 } \theta \text{ 无关})$$

**MLE**和**MAP**的不同在于是否有先验项。



**例** 设某事件  $A$  在一次试验中发生的概率为  $\theta$ , 为估计  $\theta$ , 对试验进行了  $n$  次独立观测, 其中事件  $A$  发生了  $X$  次,

显然  $X | \theta \sim B(n, \theta)$ , 即

$$P(X = x | \theta) = C_n^x \theta^x (1 - \theta)^{n-x}, x = 0, 1, \dots, n.$$

假若我们在试验前对事件  $A$  没有什么了解, 从而对其发生的概率  $\theta$  也没有任何信息. 在这种场合, 贝叶斯本人建议采用“**同等无知**”的原则使用区间  $(0,1)$  上的均匀分布  $U(0,1)$  作为  $\theta$  的先验分布, 因为它取  $(0,1)$  上的每一点的机会均等. 贝叶斯的这个建议称为**贝叶斯假设**.

利用贝叶斯公式求出  $\theta$  的后验分布:

$X$  和  $\theta$  的联合分布

$$h(x, \theta) = C_n^x \theta^x (1 - \theta)^{n-x}, x = 0, 1, \dots, n, 0 < \theta < 1,$$

$X$  的边缘分布

$$m(x) = C_n^x \int_0^1 \theta^x (1 - \theta)^{n-x} d\theta = C_n^x \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)},$$

$\theta$  的后验分布

$$\begin{aligned} \pi(\theta | x) &= \frac{h(x, \theta)}{m(x)} \\ &= \frac{\Gamma(n+2)}{\Gamma(x+1)\Gamma(n-x+1)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, 0 < \theta < 1. \end{aligned}$$

结果说明  $\theta | x \sim \text{Beta}(x+1, n-x+1)$

其最大后验估计  $\hat{\theta}_{MAP} = \frac{x}{n}$

其后验期望估计  $\hat{\theta}_B = \frac{x+1}{n+2}$

假如不用先验信息, 只用总体信息与样本信息, 那么事件  $A$  发生的概率的最大似然估计  $\hat{\theta}_{MLE} = \frac{x}{n}$ ,

某些场合, 贝叶斯估计要比最大似然估计更合理一点.

例如: 在产品抽样检验中只区分合格品和不合格品,  $\theta$  表示不合格品率。“抽检3个全是不合格品”与“抽检10个全是不合格品”是有差别的两个事件, 前者质量很差, 后者则不可救药.

这种差别用  $\hat{\theta}_{MLE}$  反映不出(两者都是1)

而  $\hat{\theta}_B$  分别是  $(3+1)/(3+2) = 0.80$  和  $(10+1)/(10+2) = 0.917$ .

# 点估计的评价标准

点估计具有不唯一性，即对于同一个未知参数，不同的方法得到的估计量可能不同，怎么评价一个估计量的好坏？

(1) 无系统偏差, 即  $\hat{\theta}$  平均起来应与  $\theta$  值相同, 也就是说

$E[\hat{\theta}(X_1, X_2, \dots, X_n) - \theta] = 0$ . 这就是**无偏性**的要求.

(2) 波动性小, 即  $|\hat{\theta} - \theta|$  平均起来应尽可能小, 为数学上便于处

理, 可用  $\hat{\theta}(X_1, X_2, \dots, X_n)$  的均方误差  $E[(\hat{\theta}(X_1, X_2, \dots, X_n) - \theta)^2]$

表示. 这就是**有效性**的要求.

(3) 随着样本容量  $n$  的增大,  $\hat{\theta}$  应越来越接近于  $\theta$ , 亦即  $|\hat{\theta} - \theta|$  按某种概率意义收敛于0. 这就是**相合性**的要求.

# 均方误差准则(Mean Squared Error, MSE)

定义：设 $\hat{\theta}$ 是参数 $\theta$ 的点估计，方差存在，则称

$E(\hat{\theta} - \theta)^2$ 是估计量 $\hat{\theta}$ 的均方误差，记为 $Mse(\hat{\theta})$


- 估计量的均方误差由方差(variance)和偏差(bias)两部分组成。

$$\begin{aligned}MSE(\hat{\theta}) &= E(\hat{\theta} - \theta)^2 = D(\hat{\theta} - \theta) + [E(\hat{\theta} - \theta)]^2 \\&= D(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2 = D(\hat{\theta}) + (bias(\hat{\theta}))^2\end{aligned}$$

- 均方误差越小的估计量越好。
- 在所有估计量中，均方误差最小的称为最优估计量。

# (1) 无偏性(unbiased)

估计量是随机变量，对于不同的样本值会得到不同的估计值。我们希望估计值在未知参数真值附近摆动，它的期望值等于未知参数的真值。这就是无偏性标准。



设 $\hat{\theta}(X_1, \dots, X_n)$ 是未知参数 $\theta$ 的估计量，若 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 为 $\theta$ 的**无偏估计**。

无偏估计的实际意义：无系统误差。

若 $\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 是 $\theta$ **渐近无偏估计**

(asymptotically unbiased)。

实际应用中应尽量选择无偏估计。如果无偏估计不存在或很难计算，则选择渐进无偏估计。

**例** 设总体  $X$  的  $k$  阶矩  $\alpha_k = E(X^k)$  存在,

$(X_1, X_2, \dots, X_n)$  是总体  $X$  的样本,

**证明:** 不论  $X$  服从什么分布(但  $k$  阶矩存在),

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad \text{是 } \alpha_k \text{ 的无偏估计量.}$$

**证**

$$\text{由于 } E(X_i^k) = \alpha_k \quad i=1, 2, \dots, n$$

$$E(A_k) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \frac{1}{n} \cdot n \cdot \alpha_k = \alpha_k$$

- 样本均值  $\bar{X}$  是总体期望  $E(X)$  的无偏估计量。
- 样本二阶**原点**矩  $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$  是总体二阶**原点**矩  $E(X^2)$  的无偏估计量。

例 设总体  $X$  的期望  $\mu$  与方差  $\sigma^2$  存在,  $X$  的样本为  $(X_1, X_2, \dots, X_n)$

(1) 原样本方差 (Raw sample variance)

$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  不是  $D(X)$  的无偏估计, 是  $D(X)$  的渐进无偏估计

$$E(S_n^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2;$$

$$\lim_{n \rightarrow \infty} E(S_n^2) = \lim_{n \rightarrow \infty} \frac{n-1}{n} \sigma^2 = \sigma^2$$

(2) 样本修正方差 (Bessel's Correction)

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $D(X)$  的无偏估计.

$$E(S^2) = \sigma^2$$



$$E(S_n^2) = \frac{n-1}{n} \sigma^2, \quad E(S^2) = \sigma^2$$

推导

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \mu \quad D(\bar{X}) = \frac{1}{n} \sigma^2$$

$$\begin{aligned} E(S_n^2) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - E(\bar{X}^2) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - [D(\bar{X}) + E^2(\bar{X})] \\ &= \sigma^2 + \mu^2 - \left(\frac{1}{n} \sigma^2 + \mu^2\right) = \frac{n-1}{n} \sigma^2 \end{aligned}$$


$$E(S^2) = E\left[\frac{n}{n-1} S_n^2\right] = \frac{n}{n-1} E(S_n^2) = \sigma^2$$

样本标准差是无偏的吗？

$$S \stackrel{\text{def}}{=} \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \quad \sigma = \sqrt{\sigma^2} \quad E(S) = \sigma ?$$

例 总体X服从B(1,p), 样本容量n=2  $\sigma = \sqrt{p(1-p)} = \sqrt{pq}$

$x_1, x_2$	$P(x_1, x_2)$	$\bar{x}$	$s^2$	$s$
0,0	$q^2$	0	0	0
0,1	$qp$	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{\sqrt{2}}$
1,0	$pq$	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{\sqrt{2}}$
1,1	$p^2$	1	0	0



$$E(S) = q^2 \cdot 0 + qp \cdot \frac{1}{\sqrt{2}} + pq \cdot \frac{1}{\sqrt{2}} + p^2 \cdot 0 = \sqrt{2} \cdot pq < \sqrt{pq}$$

一般的 $\sigma$ 无偏估计量不存在。

例 设总体  $X$  的密度函数为 
$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0, \\ 0 & x \leq 0 \end{cases}$$

$\theta > 0$  为参数,  $X_1, X_2, \dots, X_n$  为  $X$  的一个样本.

求  $\theta$  的最大似然估计量, 并判断它是否无偏估计量.

解 似然函数 
$$L(\theta) = \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum_{i=1}^n x_i}, \quad x_i > 0 \quad \ln L(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n x_i$$

$$\frac{d}{d\theta} \ln L(\theta) = -\frac{n}{\theta} + \frac{\sum_{i=1}^n x_i}{\theta^2} \stackrel{\text{令}}{=} 0 \quad \longrightarrow \quad \hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$\theta$  的最大似然估计量为 
$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

$E(\hat{\theta}) = E(\bar{X}) = E(X) = \theta$  是无偏估计量.

设  $\lambda = \frac{1}{\theta}$ ,  $\lambda$  的最大似然估计量是什么? 是无偏估计吗?

$$\hat{\lambda} = \frac{1}{\hat{\theta}} = \frac{1}{\bar{X}} \quad E(\hat{\lambda}) = E\left(\frac{1}{\bar{X}}\right) \neq \frac{1}{E(\bar{X})} = \lambda$$

例

设  $X_1, X_2, \dots, X_n$  是取自  $P(\lambda)$  的样本, 证明  $\bar{X}$ ,

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \text{ 和 } a\bar{X} + (1-a)S^2 \quad (0 \leq a \leq 1)$$

都是  $\lambda$  的无偏估计.

解

$$X \sim P(\lambda) \Rightarrow E(X) = D(X) = \lambda$$

$$E(\bar{X}) = E(X) = \lambda$$

$$E(S^2) = D(X) = \lambda$$

$$\begin{aligned} E[a\bar{X} + (1-a)S^2] &= aE(\bar{X}) + (1-a)E(S^2) \\ &= [a + (1-a)]\lambda = \lambda \end{aligned}$$

## (2) 有效性

一个参数往往有不只有一个无偏估计, 若 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 都是参数 $\theta$ 的无偏估计量, 二者谁更优?

由无偏估计的性质得到  $E(\hat{\theta}_1) = \theta$        $E(\hat{\theta}_2) = \theta$

$$MSE(\hat{\theta}_1) = E(\hat{\theta}_1 - \theta)^2 = D(\hat{\theta}_1)$$

$$MSE(\hat{\theta}_2) = E(\hat{\theta}_2 - \theta)^2 = D(\hat{\theta}_2)$$

无偏估计中方差小的更好, 这就是“**有效性**”.

- 设 $\hat{\theta}_1$ 、 $\hat{\theta}_2$ 是未知参数 $\theta$ 的两个无偏估计量, 若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ , 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$  **有效**(efficient).
- 设 $\hat{\theta}^*$ 是未知参数 $\theta$ 的无偏估计量, 若对于 $\theta$ 的任意一个无偏估计量 $\hat{\theta}$ , 都有 $D(\hat{\theta}^*) \leq D(\hat{\theta})$ , 则称 $\hat{\theta}^*$ 为 $\theta$ 的**最小方差无偏估计**.

**例** 设总体  $X$  的均值  $E(X) = \mu$  未知,  $-\infty < \mu < +\infty$ ,  $(X_1, X_2, \dots, X_n)$  是取自总体  $X$  的样本, 在形如  $\hat{\mu} = \sum_{i=1}^n a_i X_i$  且  $\sum_{i=1}^n a_i = 1$  的无偏估计量中, 求出最小方差无偏估计量  $\hat{\mu}^*$ 。

解 记  $D(X) = \sigma^2$ , 则

$$D(\hat{\mu}) = D\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 D(X_i) = \left(\sum_{i=1}^n a_i^2\right) \sigma^2.$$

问题归结为在条件  $\sum_{i=1}^n a_i = 1$  下, 求  $a_1, a_2, \dots, a_n$  使  $\sum_{i=1}^n a_i^2$  取得最小值.

$$1 = \left(\sum_{i=1}^n c_i\right)^2 = \sum_{i=1}^n c_i^2 + 2 \sum_{1 \leq i < j \leq n} c_i c_j \leq \sum_{i=1}^n c_i^2 + \sum_{1 \leq i < j \leq n} (c_i^2 + c_j^2) = n \sum_{i=1}^n c_i^2$$

即  $\sum_{i=1}^n c_i^2 \geq \frac{1}{n}$

当  $a_1 = a_2 = \dots = a_n = \frac{1}{n}$ , 即  $\hat{\mu} = \hat{\mu}^* = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  时,  $D(\hat{\mu})$  取得最小值  $D(\hat{\mu}^*) = \frac{1}{n} \sigma^2$ .

样本均值  $\bar{X}$  是形如  $\sum_{i=1}^n a_i X_i$  且  $\sum_{i=1}^n a_i = 1$  的无偏估计量中方差最小的.

### (3) 一致性(相合性, **consistence**)

无偏性和有效性都是在样本容量  $n$  固定的前提下提出的, 随着试验次数  $n$  的不断增加, 样本所包含的信息量也逐步增加. 因此, 一个“好”的估计在样本容量  $n$  增加时, 必须越来越接近于参数的真值.

**定义** 设  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  是总体参数  $\theta$  的估计量.

若  $n \rightarrow \infty$  时,  $\hat{\theta}$  依概率收敛于  $\theta$ , 即

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| \geq \varepsilon) = 0$$

则称  $\hat{\theta}$  是参数  $\theta$  的一致(或相合)估计量.

- 一致性估计量仅在样本容量  $n$  足够大时, 才显示其优越性.
- 样本  $k$  阶矩是总体  $k$  阶矩的一致性估计量
- 矩估计量一般为一致估计量
- 在一定条件下, 极大似然估计具有一致性

**定理 (马尔可夫不等式)** 设  $g(X)$  是随机变量  $X$  的非负连续函数, 如果  $E[g(X)]$  存在, 则对于任一正常数  $c$ , 均有

$$P\{g(X) \geq c\} \leq \frac{E[g(X)]}{c}.$$

证 由于  $g$  是非负连续函数, 所以

$$\begin{aligned} E[g(X)] &= \int_{-\infty}^{+\infty} g(x)f(x)dx \geq \int_{\{x|g(x)\geq c\}} g(x)f(x)dx \\ &\geq c \int_{\{x|g(x)\geq c\}} f(x)dx = cP\{g(X) \geq c\}, \end{aligned}$$

由  $c > 0$  知,  $P\{g(X) \geq c\} \leq \frac{E[g(X)]}{c}$  成立.  $\square$



**定理** 设  $\hat{\theta}_n$  是  $\theta$  的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \lim_{n \rightarrow \infty} D(\hat{\theta}_n) = 0,$$

则  $\hat{\theta}_n$  是  $\theta$  的相合估计.

**证** 对任给的  $\varepsilon > 0$ , 有

$$P(|\hat{\theta}_n - \theta| \geq \varepsilon) = P((\hat{\theta}_n - \theta)^2 \geq \varepsilon^2) \leq \frac{E(\hat{\theta}_n - \theta)^2}{\varepsilon^2} \quad (\text{马尔可夫不等式}).$$

又  $D(\hat{\theta}_n) = D(\hat{\theta}_n - \theta) = E(\hat{\theta}_n - \theta)^2 - [E(\hat{\theta}_n - \theta)]^2$ , 得

$$P(|\hat{\theta}_n - \theta| \geq \varepsilon) \leq \frac{D(\hat{\theta}_n) + [E(\hat{\theta}_n - \theta)]^2}{\varepsilon^2} = \frac{D(\hat{\theta}_n) + [E(\hat{\theta}_n) - \theta]^2}{\varepsilon^2},$$

根据已知条件, 当  $n \rightarrow \infty$  时,  $E(\hat{\theta}_n) \rightarrow \theta, D(\hat{\theta}_n) \rightarrow 0$ ,

故  $P(|\hat{\theta}_n - \theta| \geq \varepsilon) \rightarrow 0$ , 因而  $\hat{\theta}_n$  是  $\theta$  的相合估计.

**例** 若总体 $X$ 的  $E(X) = \mu$  和  $D(X) = \sigma^2$  存在, 则样本均值  $\bar{X}$  是总体均值  $\mu$  的相合估计.

**证明** 由于  $E(\bar{X}) = E(X) = \mu,$

$$\lim_{n \rightarrow \infty} D(\bar{X}) = \lim_{n \rightarrow \infty} \frac{D(X)}{n} = \lim_{n \rightarrow \infty} \frac{\sigma^2}{n} = 0$$

故  $\bar{X}$  是  $\mu$  的相合估计.

例 设总体  $X \sim N(\mu, \sigma^2)$ ,  $X_1, \dots, X_n$  是  $X$  的一个样本,

则  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $\sigma^2$  的相合估计量.

证明

$$\frac{(n-1) S^2}{\sigma^2} \sim \chi^2(n-1) \quad \text{由卡方分布性质知}$$
$$E\left(\frac{(n-1) S^2}{\sigma^2}\right) = n-1, \quad D\left(\frac{(n-1) S^2}{\sigma^2}\right) = 2(n-1)$$

$$\therefore E(S^2) = \sigma^2, \quad D(S^2) = \frac{2\sigma^4}{n-1}$$

$$\lim_{n \rightarrow \infty} E(S^2) = \sigma^2, \quad \lim_{n \rightarrow \infty} D(S^2) = 0$$

$S^2$  是  $\sigma^2$  的相合估计量.

# 无偏估计量方差的下界

- **问题：** 在样本容量一定的条件下, 待估参数的无偏估计量的方差是否可以任意小呢?
- Rao-Cramér 定理

## Rao-Cramér 定理

设总体  $X$  的概率密度函数为  $f(x; \theta)$ ,  $\theta \in \Theta$ , 这里  $\Theta$  是  $(-\infty, +\infty)$  上的一个开区间,  $(X_1, X_2, \dots, X_n)$  是取自总体  $X$  的样本, 待估函数是  $g(\theta)$ , 且  $\hat{g}(X_1, X_2, \dots, X_n)$  是  $g(\theta)$  的任意一个无偏估计量, 如果

$$(1) E \left[ \left( \frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right] > 0,$$

$$(2) \frac{\partial}{\partial \theta} f(x; \theta) \text{ 存在, 且 } \frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} f(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial}{\partial \theta} f(x; \theta) dx,$$

$$(3) \frac{\partial}{\partial \theta} g(\theta) \text{ 存在, 且}$$

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} \hat{g}(x_1, \dots, x_n) \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} \hat{g}(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left( \prod_{i=1}^n f(x_i; \theta) \right) dx_1 \cdots dx_n, \end{aligned}$$

则有  $D[\hat{g}(X_1, X_2, \dots, X_n)] \geq \frac{[g'(\theta)]^2}{nI(\theta)}$ ,

其中  $I(\theta) = E \left[ \left( \frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right]$  称为 **Fisher 信息量**,

右端的  $\frac{[g'(\theta)]^2}{nI(\theta)}$  称为 **Rao-Cramér 下界**.

• 特别地, 当  $g(\theta) = \theta$  时,  $D[\hat{\theta}(X_1, X_2, \dots, X_n)] \geq \frac{1}{nI(\theta)}$

表明, 如果未知参数  $\theta$  的某个无偏估计量  $\hat{\theta}$ , 其方差  $D(\hat{\theta})$  等于 Rao-Cramér 下界  $\frac{1}{nI(\theta)}$ , 那么这个无偏估计量  $\hat{\theta}$  必是**最小方差无偏估计量**.

• 设  $\hat{g}(X_1, X_2, \dots, X_n)$  是待估函数  $g(\theta)$  的一个无偏估计量,

$$e(\hat{g}) = \frac{[g'(\theta)]^2}{nI(\theta)} / D(\hat{g})$$

称为无偏估计量  $\hat{g}$  的**效率**. 显然  $e(\hat{g}) \leq 1$ , 如果  $e(\hat{g}) = 1$ , 则称  $\hat{g}$  为  $g$  的**优效估计**; 如果  $\hat{g}$  满足  $\lim_{n \rightarrow +\infty} e(\hat{g}) = 1$ , 则称  $\hat{g}$  为  $g$  的**渐近优效估计**.

## Fisher 信息量

$$\begin{aligned}\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) &= \frac{\partial}{\partial \theta} \left[ \frac{\partial}{\partial \theta} \ln f(X; \theta) \right] = \frac{\partial}{\partial \theta} \left[ \frac{1}{f(X; \theta)} \frac{\partial}{\partial \theta} f(X; \theta) \right] \\&= - \left[ \frac{1}{f(X; \theta)} \frac{\partial}{\partial \theta} f(X; \theta) \right]^2 + \frac{1}{f(X; \theta)} \frac{\partial^2}{\partial \theta^2} f(X; \theta) \\&= - \left( \frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 + \frac{1}{f(X; \theta)} \frac{\partial^2}{\partial \theta^2} f(X; \theta),\end{aligned}$$

$$\begin{aligned}E \left[ \frac{1}{f(X; \theta)} \frac{\partial^2}{\partial \theta^2} f(X; \theta) \right] &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} \frac{\partial^2}{\partial \theta^2} f(x_1, \cdots, x_n; \theta) dx_1 \cdots dx_n \\&= \frac{\partial^2}{\partial \theta^2} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(x_1, \cdots, x_n; \theta) dx_1 \cdots dx_n = 0,\end{aligned}$$

$$I(\theta) = E \left[ \left( \frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right] = -E \left( \frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right)$$

**例** 设  $(X_1, X_2, \dots, X_n)$  是取自总体  $B(1; p)$  的一个样本, 其中  $p \in [0, 1]$  但未知, 求  $p$  的无偏估计量方差的下界.

**解:**  $X$  的概率密度函数为  $f(x; p) = p^x(1-p)^{1-x}, x = 0, 1$ .

$$\frac{\partial}{\partial p} \ln f(x; p) = \frac{\partial}{\partial p} \{x \ln p + (1-x) \ln(1-p)\} = \frac{x}{p} - \frac{1-x}{1-p} = \frac{x-p}{p(1-p)},$$

$$\begin{aligned} I(p) &= E \left[ \left( \frac{X-p}{p(1-p)} \right)^2 \right] = \frac{1}{p^2(1-p)^2} E[(X-p)^2] \\ &= \frac{1}{p^2(1-p)^2} D(X) = \frac{1}{p^2(1-p)^2} p(1-p) = \frac{1}{p(1-p)}. \end{aligned}$$

因此,  $p$  的无偏估计量的方差下界是  $\frac{p(1-p)}{n}$ .

如果取样本均值  $\bar{X}$  为  $p$  的估计量, 它显然是无偏估计量, 由  $D(\bar{X}) = \frac{1}{n} D(X) = p(1-p)/n$  知,  $\bar{X}$  的方差等于 Rao-Cramér 下界  $p(1-p)/n$ , 故  $\bar{X}$  是  $p$  的最小方差无偏估计量.



**例** 设  $(X_1, X_2, \dots, X_n)$  是取自正态总体  $N(\mu; \sigma^2)$  的样本, 讨论  $\mu$ 、 $\sigma^2$  的无偏估计量的方差下界.

**解** 
$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\},$$

$$\ln f(x; \mu, \sigma^2) = -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}(x - \mu)^2.$$

(1)  $\mu$  的无偏估计的方差下界

$$\frac{\partial}{\partial \mu} \ln f(x; \mu, \sigma^2) = \frac{x - \mu}{\sigma^2}, \quad \frac{\partial^2}{\partial \mu^2} \ln f(x; \mu, \sigma^2) = -\frac{1}{\sigma^2}, \quad I(\mu) = \frac{1}{\sigma^2}.$$

于是,  $\mu$  的无偏估计的方差下界是  $\sigma^2/n$ . 因为样本均值  $\bar{X}$  的方差  $D(\bar{X}) = \sigma^2/n$  达到这个下界, 从而  $\bar{X}$  是  $\mu$  的最小方差无偏估计量.

(2)  $\sigma^2$  的无偏估计的方差下界.

$$\frac{\partial}{\partial \sigma^2} \ln f(x; \mu, \sigma^2) = -\frac{1}{2\sigma^2} + \frac{1}{2\sigma^4} (x - \mu)^2,$$

$$\frac{\partial^2}{\partial (\sigma^2)^2} \ln f(x; \mu, \sigma^2) = \frac{1}{2\sigma^4} - \frac{(x-\mu)^2}{\sigma^6}, \text{ 得 } I(\sigma^2) = -\left(\frac{1}{2\sigma^4} - \frac{1}{\sigma^4}\right) = \frac{1}{2\sigma^4}.$$

因此,  $\sigma^2$  的无偏估计的方差下界是  $\frac{2}{n} \sigma^4$ .

• 当  $\mu$  已知时,  $\sigma^2$  的极大似然估计量  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$  是无偏的. 由于  $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$ ,  $D\left[\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2\right] = 2n$ ,  $D[\sum_{i=1}^n (X_i - \mu)^2] = 2n\sigma^4$ .

于是,  $D(\hat{\sigma}^2) = \frac{1}{n^2} D[\sum_{i=1}^n (X_i - \mu)^2] = \frac{2}{n} \sigma^4$ , 即  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$  的方差达到 Rao-Cramér下界, 因此它是  $\sigma^2$  的最小方差无偏估计量.

- 当  $\mu$  未知时, 样本方差  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $\sigma^2$  的无偏估计. 由于  $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$ ,

$$D\left[\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2\right] = 2(n-1), \quad D\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = 2(n-1)\sigma^4.$$

$$\begin{aligned} D(S^2) &= D\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{(n-1)^2} D\left(\sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= \frac{1}{(n-1)^2} \cdot 2(n-1)\sigma^4 = \frac{2}{n-1}\sigma^4 > \frac{2}{n}\sigma^4, \end{aligned}$$

即  $S^2$  的方差没有达到 Rao-Cramér 下界.

- 对于正态总体  $N(\mu; \sigma^2)$ , 样本均值  $\bar{X}$  是  $\mu$  的优效估计, 样本方差  $S^2$  是  $\sigma^2$  的渐近优效估计.

# 填空题

1分

方法一:

$$\begin{aligned} \ln p &= x \ln a - a - \ln x! \\ \text{求导: } \frac{x}{a} - 1 \\ \text{再求导: } -\frac{x}{a^2} \\ E\left(\frac{x}{a}\right) &= \frac{E(x)}{a} = \frac{1}{a} \quad \text{故} \quad \frac{1}{n E(0)} = \frac{a}{n} \end{aligned}$$

设置

设  $(X_1, X_2, \dots, X_n)$  是取自Poisson分布的样本, 概率分布是

$$P\{X = x\} = \frac{a^x}{x!} e^{-a} \quad (x = 0, 1, 2, \dots), \text{ 其中 } a > 0 \text{ 未知,}$$

$a$  的无偏估计量的方差下界是 [\[填空1\]](#).

$$\begin{aligned} \text{解: } P\{X=x\} &= \frac{a^x}{x!} e^{-a} \\ \ln p &= x \ln a - \ln x! - a \\ \frac{\partial \ln p}{\partial a} &= \frac{x}{a} - 1 \\ \therefore E\left(\frac{x}{a} - 1\right)^2 &= E\left(\frac{x^2}{a^2} - \frac{2x}{a} + 1\right) \\ &= \frac{1}{a^2} E(x^2) - \frac{2}{a} E(x) + 1 \\ &= \frac{1}{a^2} (a + a^2) - \frac{2}{a} \cdot a + 1 \\ &= \frac{1}{a} \\ \text{故为 } \frac{a}{n} \end{aligned}$$

作答